

Character.AI Model Upgrade Expectation Management

PUBLIC PORTFOLIO EDITION · CONTENT PRESERVED FROM THE AUTHOR'S SOURCE DOCUMENT

Privacy note: PDF metadata has been removed. This edition excludes DOCX author metadata, revision history, comments, and document properties. The byline “Lin Jiaxin” is retained only where it appears in the work itself.

Character.AI 版本升级预期管理

角色型 AI 产品的版本发布风险控制 · 运营方案

背景：Character.AI 将底层 9 个模型合并为 2 个自研模型（PipSqueak2 / Deep Squeak）。这次变更对轻度用户几乎无感，却可能直接击穿重度用户的留存——本方案围绕「如何在改底层模型的同时保住重度用户信任」展开。

核心结论（先看这个）

角色型产品的「人格」由 角色定义 prompt × 模型行为 × 历史对话上下文 涌现而成；模型一换，「模型行为」这个乘子变，同一角色性格就漂移。

最危险的是重度用户：他们把角色当关系养了数月，漂移对他们等于关系被单方面改写，结果是流失、声讨、逼宫退回旧模型。

我的打法：canary 灰度按风险敏感度而非用户量级铺；用四条量化护栏提前抓 drift；旧模型限时使用做低成本降级；changelog + 公告做预期管理，把强制变更变成用户可选择的过渡。

一、背景：模型一换，人格就漂

Character.AI 的「角色性格」不是写死的，而是三个变量共同涌现的结果：

角色定义 prompt：作者设定的人设与行为边界

模型行为：底层 LLM 的输出风格与一致性

历史对话上下文：长期记忆与互动积累

当底层模型被替换，第二项的输出风格与一致性整体改变，同一角色的产出性格随之偏移。对轻度用户几乎无感；对重度用户是破坏性事件——他们投入数月培养的角色，依赖的正是稳定的涌现态，漂移对他们相当于一段关系被单方面改写。

我把这次升级的运营命题重新定义为：不是「功能上线」，而是「如何在改底层模型的同时，保住重度用户的留存与信任」。

二、我识别出的四类风险（爆炸半径）

我把升级的风险拆成四类，每一类都对应不同的影响人群和业务后果：

Non-determinism: 同一角色、同一对话, 输出风格随机波动, 用户无法建立稳定预期。

Dependency 固化: 重度用户在角色培养上投入大量精力 (关系、记忆、人设), 模型升级等于抹掉其历史投入。

Persona drift: ooc (行为不符人设)、memory

失效需反复提醒、文本风格变化 (如大量旁白)、整体质量波动。

质量波动: 输出较依赖 prompt 写法; 用户若不懂重写 prompt, 人物质量会明显下降。对此我的缓解动作是提供 prompt 迁移助手 /

官方人设模板, 把「用户自己扛质量」变成「平台帮你过渡」, 降低重写成本、压缩波动窗口。

这四类风险高度集中在重度 / 高活跃用户, 且是「信任与关系」层面的流失, 不是功能层面的吐槽——所以灰度必须优先覆盖高风险人群, 而不是无差别铺量。

三、灰度方案: 先放高风险人群, 用护栏兜底

我把 canary 顺序按「风险敏感度」排, 而不是按用户量级。逻辑是: drift

对重度用户最致命, 应该让最敏感的人先暴露问题, 早停早止损。

我设了四条量化护栏, 按阶段生效、任一触发就终止 canary:

重度用户 D7 retention (全阶段): canary 期重度用户 D7 留存 vs 灰度前基线, 相对下滑 $\geq 20\%$ $\rightarrow$ 终止。

社区负面情绪占比 (全阶段, early

warning): 相对灰度前基线显著抬升即触发 (超过历史基线负面率的统计显著水平), 不等过半数负面 $\rightarrow$ 终止。

单角色人均聊天时长 (全阶段): 相对灰度前显著下降 $\geq 30\%$ $\rightarrow$ 终止。

D1 DAU (仅 25%+ 阶段): 放量足够大时全量 DAU 才有信号意义; canary 期 vs 灰度前基线下降 $\geq 20\%$ $\rightarrow$ 终止。1% / 5% 阶段放量太小、DAU 噪声大, 不依赖此条。

护栏同时看「行为指标」(retention / DAU /

时长) 与「态度指标」(社区情绪), 并随放量阶段调整灵敏度, 避免只看一端、或被早期小样本噪声误判。

四、降级: 没有干净回滚时, 用额度限制兜底

CA 的真实约束是: 变更强制、用户逼宫退回旧模型、但平台没有干净回滚通道——因为旧聊天模型非自研, 调用成本高, 无限 rollback 就背离了「改用自研模型降本」的初衷。

我的方案: 保留旧模型版本, 但限制使用额度 (如每天 ≤ 2

小时), 用户可自行选择版本。这样既守住了成本底线和自研化方向, 又给重度用户一个过渡出口, 避免 ooc / 不适应把核心体验拖垮。

横向看 Suno: 它能保留版本开关, 是因为音乐模型自研、且新模型只向付费用户开放, 对普通用户影响有限。这说明「能不能给用户版本选择权」本质是成本结构与商业化分层问题, 不是产品态度问题——方案必须按真实成本边界来设计, 而不是理想化的 rollback。

五、预期管理: 把强制变更讲成用户可选择的过渡

Changelog: 「我们将 9 个模型合并为 2 个自研模型 (PipSqueak2 / DeepSqueak), 目的是降低维护成本、让免费层长期可持续。合并后角色风格会有变化, 你可在设置里选择旧模型 (每天 ≤ 2 小时) 过渡。」

In-product 公告四要素: What changed (合并模型) / Why (降本、免费层可持续) / What it means for you (风格会变, 可选旧模型过渡) / How to give feedback (对话时直接给角色评分)。

用户选择权: 给所有人旧模型时长选项, 不强制 rollback、也不强制变更。

Beta program: power users 先试、收反馈迭代, 再全量——把「被动承受」变成「早期共建」。

六、预期结果（方案跑通长什么样）

护栏和降级不是摆设，我给这套方案定了明确的成功标准：

Canary 各阶段：重度用户 D7 retention 跌幅控制在基线 20% 以内、社区负面情绪仅小幅抬升（未触发显著水平）、单角色聊天时长无断崖——满足才推进下一档；任一越线即停、回退上一档并切旧模型额度兜底。

全量后：靠旧模型 ≤ 2 小时 fallback，把重度用户因 drift 产生的流失压到可接受区间，而不是硬切后集体出走。

沟通侧：公告 +

评分反馈通道上线后，社区声讨从「逼宫退回旧模型」转为「提建议优化新模型」，把对抗情绪导成产品反馈。

一句话：目标是用可控的小范围暴露换全量的稳，而不是赌一次全量不出事。

七、沉淀：这套方法能复用到任何 AI 产品版本变更

先找「谁最痛」：重度用户的流失是关系型而非功能型，资源要先投到最敏感的人群。

任何发布都要有可测的停止线：把「好像变差了」这种主观感受，变成 retention / DAU / 情绪阈值的客观条件，且阈值要随阶段调灵敏度。

rollback 不是非黑即白：额度限制是真实约束下的可行解；对比竞品能帮你校准方案边界。

用选择权替代强制：变更沟通讲清 what / why / means / feedback，降低对抗、保住信任。

给动作也要给成功标准：方案不能只列「做什么」，要定义「做成什么样」，否则没法判断是否该停。

TABLE CONTENT

阶段	放量	覆盖人群	为什么是这群人
1	1%	TOP 50 创作者	创作要求极高、UGC 多、对模型最敏感，且有粉丝基础，反馈最具代表性
2	5%	TOP 100 创作者	有较高创作要求，对模型变化较敏感
3	25%	高活跃用户（日消息 ≥ 200 、注册 ≥ 1 年、周登录 ≥ 5 天）	与角色互动最高、依赖最强，微小变化即能察觉
4	50%	次活跃用户（日消息 ≥ 50 、注册 ≥ 1 年、周登录 ≥ 4 天）	活跃度高于均值，作中风险验证
5	100%	其余全部用户	对更新不敏感、未形成长期依赖，最后全量